Calculo matricial

D'Gradiente da constante é zero →
$$f(\vec{x}) = Cte$$
 $\nabla f = \vec{o}$

2)
$$f(\vec{x}) = \vec{x}^{T} \cdot \vec{\alpha} \Rightarrow \nabla f = \vec{d}$$

[Ixin | fixed constants

3
$$f(\vec{x}) = \vec{x}^T A \vec{x} \Rightarrow \nabla f = (A + A^T) \vec{x}$$

 $A = A^T \Rightarrow \nabla f = 2 \cdot A \vec{x}$

Coisas de matriz:
$$(A+B)^T = A^T + B^T$$

 $(AB)^T = B^T A^T$

Aplicando as regras do calculo matricial ao MSE, temos:

$$\nabla MSE = \frac{1}{m} \left(2 X^T X \Theta - 2 X^T Y \right)$$

$$\nabla MSE = \vec{O} \Rightarrow \frac{1}{m} \left(2 X^T X \theta - 2 X^T y \right) = \vec{O} \Rightarrow$$

$$\Rightarrow 2 \times T \times \theta = 2 \times T y \Rightarrow \left[\Theta_{qq} = \left(X^T \times \right)^{-1} X^T y \right]$$
Equação normal

Chuanto custa calcular Dop+?

$$\Theta_{\text{opt}} = \left(\chi^{T}\chi\right)^{\underbrace{1}} \cdot \chi^{T}y \quad O(n^{3})$$

$$O(mn^{2}) \quad O(mn)$$

Modelo linear para regressão

$$\hat{y} = \Theta_0 + \Theta_1 \cdot X_1 + \Theta_2 X_2 + \dots + \Theta_n X_n$$

notação matricial:

$$\hat{y} = X \Theta$$
, onde: $\hat{y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_m \end{bmatrix} \Theta = \begin{bmatrix} \Theta_0 \\ \Theta_1 \\ \vdots \\ \Theta_n \end{bmatrix}$

$$X = \begin{bmatrix} 1 & \times_{11} & \times_{12} & \cdots & \times_{1n} \\ 1 & \times_{21} & \times_{22} & \cdots & \times_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & \times_{m1} & \times_{m2} & \cdots & \times_{mn} \end{bmatrix}$$

$$MSE = \frac{1}{m} \left(X\Theta - y \right)^{T} \left(X\Theta - y \right) = \frac{1}{m} \left(\Theta^{T} X^{T} X\Theta - 2\Theta^{T} X^{T} y \right)$$

$$= \frac{1}{m} \left(\Theta^{T} X^{T} X\Theta - 2\Theta^{T} X^{T} y \right)$$

$$\nabla MSE = \frac{1}{m} \left(2x x^T \theta - 2 x^T y \right)$$

Equação normal:

$$\nabla MSE = 0 \Rightarrow \frac{1}{m} \left(2x^{T} x \theta - 2x^{T} y \right) = \vec{0}$$

$$\Theta = \left(x^{T} x \right)^{-1} x^{T} y$$

1)
$$y = \theta_0 + \theta_1 x$$

$$y' = \theta_0 + \theta_1 x + \theta_2 x^2$$

$$\hat{y} = \Theta_0 + \Theta_1 \times + \Theta_2 \cdot COS \left[\left(\frac{\pi}{5} \right) \left(\times \right) \right] + \theta_3 \cdot sin$$

$$\left[\left(Y_{5}\right) \left(x\right) \right]$$

notação matricial:

$$\begin{array}{c}
1) \Theta = \begin{bmatrix} \Theta_0 \\ \Theta_1 \end{bmatrix}; \quad X = \begin{bmatrix} 1 & X_{11} \\ 1 & X_{21} \\ 1 & X_{m1} \end{bmatrix}; \quad y = \begin{bmatrix} y_1 \\ y_2 \\ y_m \end{bmatrix}$$

2)
$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix}$$
 ; $x = \begin{bmatrix} 1 & x_{11} & x_{21} \\ 1 & x_{21} & x_{22} \\ \vdots & \vdots & \vdots \\ 1 & x_{m1} & x_{m1} \end{bmatrix}$

3)
$$\Theta = \begin{bmatrix} \Theta_0 \\ \Theta_1 \\ \Theta_2 \\ \Theta_3 \end{bmatrix}$$
; $X = \begin{bmatrix} 1 & \chi_{11} & Cos(...) & sin(...) \\ 1 & \chi_{21} & cos(...) & sin(...) \\ 1 & \chi_{m1} & cos(...) & sin(...) \end{bmatrix}$


Intuição geometrica:

$$MSE(\theta) = \frac{1}{m} (\theta^T x^T x \theta^T - 2\theta^T x^T y + y^T y)$$

Ato de fré: MSE(0) é um paraboloide em 0

Exemple:

Exemplo degenerado:



Gradient Descent

1) Chuta 0 (0) · iteração

2) Enquanto mão acabou":
$$\theta^{(i+1)} = \theta^{(i)} - \eta \nabla MSE(\theta^{(i)})$$
taxa de aprendiçador


3) Retorna o ultimo 0

Lembrando que:

$$\nabla MSE = \frac{1}{m} \left(2 \times T \times \Theta - 2 \times Ty \right) = \frac{1}{m} 2 \times T \left(\times \Theta - y \right)$$

Criterio de parada Le 110(i+1) - 0(i) | < tolerância ou se i > maximo_de ite pode parar intução gernétrica do gradient descent: 2) Tarca de aprendizagem muito pequena

MSE



3) Taxa de aprendijado miito grande

MSE

DIVERGE

Modeles lineares

· conjunto de dados:

$$D = \{ (\vec{x_1}, y_1), (\vec{x_2}, y_2), ..., (\vec{x_n}, y_n) \}$$

ou

· notação matricial:

$$Xi = \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{bmatrix}$$
 (matriz - coluna)

$$X = \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_m^T \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}$$

$$X \in M_{m,n}(\mathbb{R})$$

modelo: ho: R" -> R (negressão)

sparametros { classes} (classificação)

truináveis

denota previsão do modelo

$$\hat{y} = ho(x) \rightarrow \hat{y} = [\hat{y}_1] \rightarrow matriz-celuna
(veter) das
previsões

jm$$

$$\mathcal{E} = \begin{bmatrix} \mathcal{E}_1 \\ \mathcal{E}_2 \\ \vdots \\ \mathcal{E}_m \end{bmatrix} = \begin{bmatrix} \dot{y}_1 - \dot{y}_1 \\ \dot{y}_2 - \dot{y}_2 \\ \dot{y}_m - \dot{y}_m \end{bmatrix} = \begin{bmatrix} \dot{y}_1 \\ \dot{y}_2 \\ \dot{y}_m \end{bmatrix} - \begin{bmatrix} \dot{y}_1 \\ \dot{y}_2 \\ \dot{y}_m \end{bmatrix}$$

$$\varepsilon = \dot{y} - \dot{y}$$

erro médio quadratico (MSE)

$$MSE = \frac{1}{m} \sum_{i=1}^{m} \mathcal{E}_{i}^{2} = \frac{1}{m} \mathcal{E}^{T} \mathcal{E}$$

Agera, o modele linear
$$he(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + ... + x_n \cdot \theta_n$$
features

-Treinar o modelo:

Descobrir
$$\Theta = \begin{bmatrix} G_0 \\ O_1 \\ \Theta_2 \\ \vdots \\ G_n \end{bmatrix}$$
 que minimiza σMSE

Um modelo de ML:

- 1) Dados
- 2) Função de erro
- 3) Modelo
- 4) Algoritmo de treinamento

Defina:
$$\chi_{\lambda}^{1} = \begin{bmatrix} 1 \\ \chi_{1} \\ \chi_{2} \\ \dots \\ \chi_{n} \end{bmatrix}$$

Com isso:
$$\hat{y} = \Theta_0 + \Theta_1 \cdot X_1 + \Theta_2 \cdot X_2 + ... + \Theta_n X_n$$

$$\hat{y} = X'^T \cdot \Theta$$

Portanto, defina:

$$X = \begin{bmatrix} 1 & - x_1^T \\ 1 & - x_2^T \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ 1 & - x_m^T \end{bmatrix}$$

$$\dot{y} = \begin{bmatrix} \dot{y}_1 \\ \dot{y}_2 \\ \vdots \\ \dot{y}_m \end{bmatrix} = \begin{bmatrix} 1 - X_1 T - 1 \\ 1 - X_2 T - 1 \end{bmatrix} \begin{bmatrix} \Theta_0 \\ \Theta_1 \\ \Theta_2 \\ \vdots \\ \Theta_n \end{bmatrix} = X \cdot \Theta$$

Juntando as partes:

$$MSE = \frac{1}{m} \cdot \left(\mathring{y}^{T} \mathring{y} - 2\mathring{y}^{T} y + y^{T} y \right) = MMDDDD$$

$$= \frac{1}{m} \left((x\Theta)^{T} (x\Theta) - 2(x\Theta)^{T} y + y^{T} y \right) = \frac{1}{m} \left(\theta^{T} x^{T} x \Theta - 2 \theta^{T} x_{y}^{T} + y^{T} y \right)$$

$$\nabla MSE = \begin{bmatrix} \frac{\partial MSE}{\partial \theta_0} \\ \frac{\partial MSE}{\partial \theta_0} \end{bmatrix} = 0$$

$$\frac{\partial MSE}{\partial \theta_2}$$

$$\frac{\partial MSE}{\partial \theta_0}$$

$$\frac{\partial MSE}{\partial \theta_0}$$